

Resumen — Se presentó un estudio comparativo riguroso de algoritmos metaheurísticos bioinspirados aplicados al Problema de Ruteo de Vehículos (VRP) sobre instancias Solomon. El análisis incluye dieciséis algoritmos recientes (2016–2025) —como WOA, MRFO, FSA y SMA— evaluados mediante *benchmarking* masivo con 1.000 ejecuciones por algoritmo. Se implementaron pruebas estadísticas avanzadas: test de Friedman alineado, prueba post-hoc de Nemenyi y medición del tamaño del efecto mediante A12 de Vargha-Delaney, complementadas con diagramas de diferencia crítica (CD). Los resultados establecen cuatro niveles de rendimiento estadísticamente significativos, destacando WOA como superior, seguido por FSA, MRFO y SMA, sin diferencias significativas entre estos cuatro. El análisis coste-calidad revela que SMA ofrece el mejor equilibrio, reduciendo el tiempo computacional en un 47 % frente a WOA, manteniendo calidad equivalente. Se proporciona un conjunto completo de herramientas de reproducibilidad científica, incluyendo código, datos y entorno de experimentación.

Palabras Clave - metaheurísticas bioinspiradas, *vehicle routing problem*, análisis estadístico, reproducibilidad, diagramas de diferencia crítica.

1. Introducción

El Problema de Ruteo de Vehículos (VRP) constituye uno de los desafíos fundamentales en investigación operativa y optimización combinatoria, con aplicaciones críticas en logística, transporte y cadenas de suministro [1]. Su naturaleza NP-difícil ha impulsado el desarrollo de múltiples enfoques metaheurísticos, destacando los algoritmos bioinspirados por su capacidad para encontrar soluciones de alta calidad en tiempos razonables.

En los últimos años, se ha producido una proliferación significativa de algoritmos metaheurísticos bioinspirados, muchos con afirmaciones de superioridad basadas en evaluaciones experimentales limitadas y pruebas estadísticas insuficientes. Esto ha generado un debate sobre la reproducibilidad y validez científica de tales comparaciones [2]. Como señalan Contreras-Saavedra et al. [3], la confianza en experimentos individuales o metodologías simplificadas puede conducir a conclusiones erróneas sobre el rendimiento algorítmico.

Además, las implementaciones disponibles suelen estar optimizadas para problemas específicos, dificultando la comparación justa entre algoritmos. Silva et al. [4] demostraron que muchos estudios comparativos carecen de evaluaciones estadísticas rigurosas, lo que limita su validez científica.

Este artículo aborda estas limitaciones presentando un estudio comparativo riguroso de dieciséis algoritmos bioinspirados recientes (2016–2025) aplicados a instancias estándar del VRP Solomon. Las contribuciones principales incluyen:

1. La implementación y evaluación sistemática de algoritmos bioinspirados en un marco común para el VRP.
2. Un enfoque estadístico robusto que supera las limitaciones de estudios previos, incorporando test de Friedman alineado, prueba post-hoc de Nemenyi y medición de tamaños de efecto A12.
3. Análisis coste-calidad que evalúa no solo la calidad de las soluciones sino también la eficiencia computacional.
4. Un marco experimental completamente reproducible, con código, datos y herramientas estadísticas disponibles.

2. Trabajos relacionados

La investigación en metaheurísticas bioinspiradas para el VRP ha experimentado un crecimiento significativo, destacando varios desarrollos recientes:

Algoritmos inspirados en comportamiento de mamíferos WOA (Whale Optimization Algorithm) [1] ha demostrado rendimiento competitivo en VRP, adaptando el comportamiento de alimentación de ballenas jorobadas mediante operadores específicos para permutaciones. SHO (Spotted Hyena Optimizer) [5] aprovecha las estrategias de caza cooperativa de las hienas, mientras que FOA (Fossa Optimization Algorithm) [6] adapta las tácticas de caza territorial de estos predadores de Madagascar. GTO (Gorilla Troops Optimization) [7] y su versión mejorada EGTO [8] modelan la estructura social jerárquica de los gorilas.

Algoritmos inspirados en aves HHO (Harris Hawks Optimization) [9] implementa la estrategia de caza cooperativa “sorpresa-pounce” de los halcones, mostrando eficaz exploración pero riesgo de convergencia prematura. FSA (Flamingo Search Algorithm) [10] adapta el comportamiento de filtración y socialización de los flamencos, mientras que SMO (Starling Murmuration Optimizer) [11] simula los movimientos coordinados de bandadas de estorninos.

Algoritmos inspirados en organismos acuáticos MRFO (Manta Ray Foraging Optimization) [12] modela tres estrategias de alimentación de las mantarrayas, mostrando buen equilibrio exploración-explotación. SMA (Slime Mould Algorithm) [2] se inspira en el comportamiento adaptativo del moho viscoso al buscar nutrientes, destacando por su enfoque adaptativo de pesos. Elsis et al. [13] han mejorado el rendimiento de SMA para CVRP mediante la incorporación de redes neuronales profundas, demostrando la capacidad de estos algoritmos para integrarse con técnicas de aprendizaje automático.

Otros enfoques bioinspirados APO (Artificial Protozoa Optimizer) [14] implementa los movimientos y división de protozoarios, mientras que AHA (Artificial Hummingbird Algorithm) [15] imita el comportamiento de los colibríes. EWA (Earthworm Algorithm) [16] modela los movimientos de los gusanos de tierra, y RRO (Raven Roosting Optimization) [17] simula el comportamiento social de los

cuervos. GVOA (Griffon Vultures Optimization Algorithm) [18] implementa estrategias de búsqueda basadas en buitres.

Enfoques híbridos para VRP Los algoritmos híbridos están ganando tracción por su capacidad de combinar fortalezas de diferentes metaheurísticas. Liang et al. [19] proponen un enfoque que combina algoritmo de armonía y algoritmo mayfly para el CVRPTW, demostrando superioridad sobre las metaheurísticas individuales. Rodríguez-Álvarez et al. [20] presentaron una búsqueda de vecindario variable complementaria que mejora la robustez de las soluciones para VRP bajo incertidumbre.

Evaluación estadística rigurosa Contreras-Saavedra et al. [3] argumentan convincentemente por la necesidad de evaluaciones multi-instancia rigurosas, proponiendo diagramas de diferencia crítica (CD) como herramienta esencial para evitar conclusiones erróneas basadas en experimentos únicos. Silva et al. [4] han establecido un marco comparativo completo que incorpora inferencia estadística robusta, demostrando inconsistencias en evaluaciones previas de algoritmos bioinspirados para VRP.

A pesar de estos avances, la mayoría de estudios comparativos presentan limitaciones metodológicas significativas [2]: (1) número insuficiente de ejecuciones independientes para lograr significancia estadística, (2) ausencia de pruebas estadísticas rigurosas más allá de simples comparaciones de medias, (3) falta de consideración del coste computacional y (4) escasa disponibilidad de código para reproducibilidad. Nuestro trabajo aborda estas limitaciones mediante un análisis sistemático con pruebas estadísticas avanzadas, siguiendo las recomendaciones metodológicas de Vargha y Delaney [21] para evaluación de tamaños de efecto.

3. Metodología

3.1. Sistema Experimental

Implementamos los dieciséis algoritmos en Python 3.11.5, asegurando un marco comparativo justo con interfaces comunes, representación unificada y funciones de evaluación idénticas. Las implementaciones siguieron estrictamente las publicaciones originales, adaptando los operadores para el dominio discreto del VRP cuando fue necesario.

Entorno computacional Apple MacBook Pro de 16 pulgadas, 2021, equipado con chip Apple M1 Pro (CPU de 10 núcleos y GPU de 16 núcleos) y 16,000 GB de memoria unificada, ejecutando macOS Sequoia 15.4.1. El entorno de experimentación se basa en Python 3.11.5 gestionado mediante pyenv. Dependencias principales: NumPy 1.23.5, Pandas 1.5.3, Matplotlib 3.8.4, SciPy 1.11.4 y scikit-posthocs 0.7.0.

Para garantizar una comparación justa, todos los algoritmos fueron configurados con parámetros recomendados en sus publicaciones originales, adaptados cuando fue necesario al dominio VRP. La Tabla 1 presentó los hiperparámetros principales utilizados para cada algoritmo.

Instancias VRP Utilizamos seis instancias estándar de la colección Solomon, abarcando distintos tipos de distribución (C: agrupada, R: aleatoria, RC: mixta) y restricciones temporales (series 101: ventanas estrechas; series 201: ventanas amplias): C101, C201, R101, R201, RC101, RC201.

Configuración de ejecución Para cada combinación algoritmo-instancia:

- 1.000 ejecuciones independientes por algoritmo en cada instancia, totalizando 96.000 ejecuciones experimentales.
- 100 iteraciones por ejecución, suficientes para observar convergencia en todos los algoritmos.
- Población de 40 individuos, un balance adecuado entre diversidad y eficiencia computacional.
- Semilla aleatoria controlada para reproducibilidad, generada de forma determinista pero única para cada ejecución.
- Paralelización para aprovechar múltiples núcleos, reduciendo el tiempo total de experimentación de meses a días.
- *Checkpointing* para recuperación automática ante fallos del sistema, evitando pérdida de datos experimentales.

Métricas registradas Para cada ejecución se registraron las siguientes métricas:

- Calidad de solución (fitness): distancia total de las rutas generadas, calculada como la suma de distancias euclidianas entre clientes consecutivos en cada ruta.
- Tiempo de ejecución total: medido con precisión de microsegundos utilizando funciones específicas del sistema operativo para minimizar interferencias.
- Tiempo promedio por iteración: calculado dividiendo el tiempo total entre el número de iteraciones, proporcionando una medida de eficiencia algorítmica independiente de la convergencia.
- Curvas de convergencia completas: documentando el progreso del fitness a lo largo de todas las iteraciones para analizar patrones de exploración/explotación.
- Uso de memoria: monitoreado durante la ejecución para detectar posibles fugas de memoria o patrones de uso ineficientes.
- Número de evaluaciones de función objetivo: para garantizar comparaciones justas independientes de las optimizaciones internas específicas de cada algoritmo.

Cuadro 1: Configuración de hiperparámetros de los algoritmos evaluados

Algoritmo	Población	Prob. Mutación	Prob. Cruce	Parámetros específicos	Estrategia de selección
WOA	40	0.3	N/A	$a = 2$ (decreciente), $b = 1$	Elitista
FSA	40	0.2	N/A	$c1 = 2$, $c2 = 1.5$	Ruleta
MRFO	40	0.15	N/A	$S = 2$ (somersault factor)	Elitista
SMA	40	0.1	0.65	$z = 0.03$ (fitness weight)	Torneos ($k=3$)
HHO	40	0.25	0.7	$E0 = 0.5$, $E1 = 0.1$	Elitista
GTO	40	0.3	0.8	$\beta = 3$, $\lambda = 1.5$	Ruleta
SHO	40	0.2	0.7	$h = 5$ (memory factor)	Elitista
APO	40	0.15	0.5	$r1 = 0.8$, $r2 = 0.2$	Torneos ($k=2$)
EWA	40	0.4	0.6	$c = 0.8$, $d = 0.2$	Ruleta
GVOA	40	0.2	0.8	$\alpha = 0.5$, $\beta = 1.5$	Elitista
EGTO	40	0.35	0.85	$\mu = 0.5$, $sr = 0.3$	Torneos ($k=3$)
OPA	40	0.25	0.75	$\alpha = 0.9$, $\beta = 0.1$	Elitista
FOA	40	0.3	0.7	$\alpha = 0.8$, $\beta = 0.7$	Ruleta
SMO	40	0.1	0.6	$sf = 0.7$, $ap = 0.3$	Elitista
RRO	40	0.5	0.6	$\alpha = 0.7$, $rp = 0.3$	Torneos ($k=2$)
AHA	40	0.4	0.8	$\alpha = 0.9$, $\beta = 0.1$	Ruleta

3.2. Análisis Estadístico Avanzado

Para superar las limitaciones de comparaciones simplistas basadas únicamente en medias y desviaciones estándar, implementamos un marco estadístico riguroso:

Test de Friedman alineado Prueba no paramétrica para comparaciones múltiples, más potente que el test de Friedman clásico al eliminar el efecto de las instancias de problema mediante alineamiento [2]. Este enfoque resulta especialmente relevante cuando se comparan algoritmos en múltiples instancias con rangos de *fitness* muy diferentes, como ocurre en las distintas series de Solomon.

Prueba post-hoc de Holm Para identificar qué pares de algoritmos presentan diferencias estadísticamente significativas cuando el test de Friedman rechaza la hipótesis nula. Genera una matriz de p-valores para comparaciones por pares y calcula la diferencia crítica (CD), que determina el

umbral para considerar dos algoritmos significativamente diferentes.

Tamaños de efecto A12 de Vargha-Delaney Complementa la significancia estadística (p-valores) con medidas de magnitud práctica de las diferencias. Siguiendo a Vargha y Delaney [21], el estadístico A12 cuantifica la probabilidad de que un algoritmo supere a otro: $A12 = 0.5$ indica rendimiento equivalente, $A12 > 0.5$ indica superioridad del primer algoritmo, con umbrales establecidos para efectos pequeños (>0.56), medianos (>0.64) y grandes (>0.71).

Diagramas de Diferencia Crítica Visualización que agrupa algoritmos sin diferencias estadísticamente significativas, conectándolos con líneas horizontales. Muestra claramente los rangos relativos y las agrupaciones estadísticas, siguiendo la metodología propuesta por Contreras-Saavedra et al. [3].

4. Resultados

4.1. Ranking General

El test de Friedman alineado arrojó $\chi^2(15) = 123.4$, $p < 0.001$, confirmando diferencias estadísticamente sig-

nificativas entre los algoritmos evaluados. La Tabla 2 mostró el ranking general de los algoritmos según este test, promediando su rendimiento en todas las instancias Solomon.

4.2. Rendimiento por Instancia

Para ilustrar el rendimiento de los algoritmos en distintos tipos de instancias, la Tabla 3 presentó el *fitness* promedio

(distancia total) con intervalos de confianza del 95 % obtenido por los cinco mejores algoritmos en cada instancia.

Los resultados mostraron que WOA obtiene el mejor rendimiento en instancias R101, RC101 y R201, mientras que FSA destaca en C101, C201 y RC201. Esto sugiere que cada algoritmo puede tener ventajas particulares según la estructura del problema. Los intervalos de confianza del 95 % proporcionan una medida de la incertidumbre

estadística, siendo notablemente más estrechos para HHO en ciertas instancias.

4.3. Tiempos de Ejecución

La Fig. 1 ilustra el tiempo promedio por iteración para cada algoritmo, factor crítico para aplicaciones prácticas.

Cuadro 2: Ranking de algoritmos según test de Friedman alineado

Posición	Algoritmo	Ranking Medio
1	WOA (Whale Optimization Algorithm)	1,670
2	FSA (Flamingo Search Algorithm)	2,670
3	MRFO (Manta Ray Foraging Optimization)	2,830
4	SMA (Slime Mould Algorithm)	2,830
5	HHO (Harris Hawks Optimization)	5,500
6	GTO (Gorilla Troops Optimization)	6,330
7	SHO (Spotted Hyena Optimizer)	6,670
8	APO (Artificial Protozoa Optimizer)	7,500
9	EWA (Earthworm Algorithm)	9,330
10	GVOA (Griffon Vultures Optimization)	10,000
11	EGTO (Enhanced Gorilla Troops Optimization)	11,000
12	OPA (Orca Predator Algorithm)	12,670
13	FOA (Fossa Optimization Algorithm)	13,500
14	SMO (Starling Murmuration Optimizer)	13,670
15	RRO (Raven Roosting Optimization)	14,670
16	AHA (Artificial Hummingbird Algorithm)	15,170

Cuadro 3: Fitness promedio (media $\pm$ IC95 %) por instancia (5 mejores algoritmos)

Alg.	C101	R101	RC101
WOA	1 521,58 $\pm$ 326.61	1 187,18 $\pm$ 612.09	1 096,68 $\pm$ 60.73
FSA	1 509,15 $\pm$ 302.65	1 598,90 $\pm$ 922.38	1 25,95 $\pm$ 107.23
MRFO	1 543,81 $\pm$ 362.70	1 451,45 $\pm$ 608.91	1 5,17 $\pm$ 105.26
SMA	1 637,63 $\pm$ 792.15	1 2,06 $\pm$ 520.37	1 6,65 $\pm$ 69.70
HHO	1 686,92 $\pm$ 432.98	1 767,76 $\pm$ 902.88	1 89,21 $\pm$ 87.10
Alg.	C201	R201	RC201
WOA	1 371,57 $\pm$ 351.07	1 4,92 $\pm$ 511.48	1 39,98 $\pm$ 70.63
FSA	1 313,60 $\pm$ 562.92	1 29,18 $\pm$ 931.00	1 3,32 $\pm$ 73.17
MRFO	1 488,17 $\pm$ 581.67	1 4,53 $\pm$ 421.48	1 7,05 $\pm$ 78.86
SMA	1 454,41 $\pm$ 472.43	1 70,70 $\pm$ 791.86	1 2,83 $\pm$ 47.10
HHO	1 584,42 $\pm$ 332.88	1 9,01 $\pm$ 482.58	1 4,93 $\pm$ 98.26




Figura 1: Tiempo promedio por iteración (ms) para cada algoritmo.

Destaca que SMA, uno de los mejores algoritmos en calidad de solución, es también uno de los más eficientes computacionalmente (1,700 ms por iteración), mientras que WOA requiere aproximadamente el doble de tiempo (3,200 ms). El algoritmo RRO mostró el peor rendimiento temporal (180,000 ms), dos órdenes de magnitud más lento

que el resto.

Para analizar la relación entre coste computacional y calidad de solución, la Fig. 2 mostró un diagrama de dispersión donde el eje x (escala logarítmica) representó el tiempo promedio por iteración y el eje y el *fitness* promedio.

Esta visualización confirma que SMA ofrece la mejor relación coste-calidad, situándose más cerca del origen (menor tiempo, menor *fitness*). RRO, a pesar de su rendimiento aceptable en *fitness*, resulta impracticable

debido a su elevado coste computacional.

4.4. Análisis Estadístico

La Fig. 3 mostró el diagrama de diferencia crítica, donde los algoritmos están ordenados por ranking (menor es mejor) y conectados por líneas horizontales cuando no existen diferencias estadísticamente significativas entre ellos. Se observan cuatro grupos principales:

1. Grupo elite: WOA, MRFO, FSA y SMA
2. Grupo secundario: HHO, GTO, SHO y APO

3. Grupo intermedio: EWA, GVOA, EGTO, OPA

4. Grupo inferior: FOA, SMO, RRO y AHA

Esta agrupación es más informativa que un simple ranking, ya que revela equivalencias estadísticas entre algoritmos.

4.5. Grupos de Rendimiento

El análisis estadístico riguroso establece cuatro grupos de rendimiento con diferencias significativas entre ellos:

Grupo elite (WOA, FSA, MRFO, SMA) Estos algoritmos demostraron rendimiento superior consistente en

todas las instancias. Su superioridad es estadísticamente significativa ($p < 0.05$) respecto a los algoritmos del tercer y cuarto grupo, y presentan tamaños de efecto grandes ($A12 > 0.71$) en comparación con los algoritmos inferiores. Dentro de este grupo, los algoritmos son estadísticamente equivalentes, sin diferencias significativas entre ellos.




Figura 2: Relación coste-calidad: tiempo por iteración vs. *fitness* promedio. Valores más bajos en ambos ejes son mejores.




Figura 3: Diagrama de Diferencia Crítica (CD = 3.24). Los algoritmos conectados por una línea no presentan diferencias estadísticamente significativas.

Grupo secundario (HHO, GTO, SHO, APO) Muestran buen rendimiento pero estadísticamente inferior al grupo elite. Las diferencias entre este grupo y el grupo elite son pequeñas a medianas ($0.56 < A_{12} < 0.71$), indicando que pueden ser competitivos en determinadas circunstancias.

Grupos inferiores Los algoritmos en los dos últimos grupos (EGTO, EWA, FOA, etc.) presentaron rendimiento significativamente inferior, con diferencias de magnitud práctica grande respecto al grupo elite ($A_{12} > 0.71$).

Estos resultados contrastan con algunas afirmaciones de la literatura. Por ejemplo, EGTO [8] fue presentado como una mejora sobre GTO, pero nuestro análisis lo sitúa en un grupo inferior. Esto podría deberse a que nuestra implementación siguió estrictamente el algoritmo original sin adaptaciones específicas para VRP.

4.6. Análisis Coste-Calidad

Un hallazgo particularmente relevante es el análisis de la relación coste-calidad, donde SMA emerge como la opción más equilibrada:

- SMA requiere 1,700 ms por iteración, aproximadamente la mitad del tiempo que WOA (3,200 ms).
- Sin embargo, no existen diferencias estadísticamente significativas en calidad de solución entre SMA y WOA ($p = 1.0$, $A_{12} = 0.53$).

5. Amenazas a la validez

En esta sección, discutimos las limitaciones de nuestro estudio y las posibles amenazas a su validez.

5.1. Validez interna

La comparación justa de algoritmos metaheurísticos presenta desafíos intrínsecos, incluso cuando se implementan en un marco común. Principalmente:

- **Implementación de algoritmos:** Aunque intentamos seguir fielmente las descripciones originales, algunas sutilezas de implementación podrían variar respecto a las versiones de los autores originales, especialmente en la adaptación al dominio discreto del VRP. Las descripciones algorítmicas en artículos científicos frecuentemente omiten detalles específicos de implementación que pueden influir significativamente en el rendimiento. Hemos documentado extensamente nuestras decisiones de implementación en el repositorio para facilitar la inspección por parte de la comunidad científica.
- **Configuración de parámetros:** Si bien utilizamos parámetros recomendados en sus publicaciones originales, no realizamos una optimización exhaustiva para cada algoritmo y cada instancia del problema. Esto podría beneficiar a algunos algoritmos sobre otros, especialmente aquellos con menor sensibilidad

Esta observación tiene importantes implicaciones prácticas: para aplicaciones con restricciones de tiempo real, SMA ofrece el mejor compromiso entre calidad y eficiencia. Por otro lado, RRO resulta impracticable debido a su elevado coste computacional, pese a rendimiento aceptable en algunas instancias.

4.7. Interpretación Biológica del Rendimiento

Resulta interesante que los algoritmos del grupo elite—WOA, FSA, MRFO y SMA—comparten características inspiradas en estrategias de búsqueda de alimento eficientes:

- WOA implementa la estrategia de “burbuja en red” de las ballenas jorobadas, un método de caza altamente cooperativo.
- MRFO combina tres estrategias de alimentación complementarias de las mantarrayas.
- SMA modela la adaptación dinámica del moho viscoso ante diferentes distribuciones de recursos.
- FSA simula comportamientos de filtración precisos y movimientos socialmente influenciados.

Esto sugiere que las metáforas biológicas más efectivas para VRP podrían ser aquellas basadas en comportamientos de *foraging* (búsqueda de alimentos) con componentes de adaptación dinámica y cooperación, más que estrategias simples de depredación.

paramétrica. Un análisis de sensibilidad completo hubiera requerido un esfuerzo computacional prohibitivo considerando la cantidad de algoritmos e instancias evaluadas.

- **Representación de soluciones:** Todos los algoritmos utilizaron la misma representación de soluciones para el VRP, lo que podría favorecer a ciertos enfoques algorítmicos sobre otros que podrían haberse beneficiado de representaciones alternativas. Esta decisión se tomó deliberadamente para garantizar comparabilidad, pero potencialmente limita el rendimiento óptimo de algunos algoritmos.
- **Operadores de búsqueda local:** No se implementaron operadores de búsqueda local específicos para VRP que podrían haber mejorado significativamente el rendimiento de algunos algoritmos. Esta decisión se tomó para evaluar la capacidad intrínseca de los algoritmos metaheurísticos, pero podría subestimar su potencial cuando se combinan con técnicas de optimización específicas del dominio.

5.2. Validez externa

Las conclusiones de este estudio deben considerarse en el contexto específico de:

- **Conjunto limitado de instancias:** Utilizamos seis instancias Solomon, lo que podría no capturar toda la variabilidad de problemas VRP reales. Aunque

seleccionamos instancias representativas de diferentes categorías (C, R, RC) y restricciones temporales (series 101 y 201), los problemas del mundo real frecuentemente presentan características adicionales como restricciones de capacidad heterogéneas, múltiples depósitos o demandas estocásticas que no están representadas en nuestro conjunto de pruebas.

- **Escalabilidad:** No evaluamos instancias de gran escala (>200 clientes), limitando la generalización de resultados a problemas de tamaño reducido o medio. Los algoritmos que mostraron buen rendimiento en nuestras pruebas podrían degradarse significativamente en problemas de mayor dimensionalidad debido a la explosión combinatoria del espacio de búsqueda.
- **Variantes del VRP:** Nuestro estudio se centró en la variante clásica del VRP con ventanas temporales, pero existen numerosas variantes como VRP con recogida y entrega simultáneas, VRP con flota heterogénea o VRP con múltiples depósitos, donde el comportamiento algorítmico podría diferir sustancialmente.
- **Aplicabilidad a otros dominios:** Aunque el VRP es un problema representativo de optimización combinatoria, las conclusiones podrían no generalizarse directamente a otros dominios de aplicación como planificación de tareas, diseño de redes o problemas de empaquetado, donde las características del espacio de búsqueda difieren significativamente.

5.3. Validez de constructo

- **Métricas de evaluación:** Priorizamos la distancia total como métrica principal, cuando en aplicaciones reales podrían ser relevantes otros factores como balance de carga, robustez ante incertidumbre o restricciones de tiempo.
- **Tiempo computacional:** La eficiencia se midió en términos de tiempo por iteración, que podría no corresponder directamente con el tiempo necesario para alcanzar soluciones de calidad similar.

5.4. Validez estadística

Si bien implementamos pruebas estadísticas rigurosas, existen varias consideraciones importantes respecto a la metodología estadística empleada:

- **Independencia de muestras:** Asumimos independencia entre ejecuciones, aunque utilizamos la misma semilla inicial para todos los algoritmos en cada instancia. Esta decisión metodológica podría introducir correlaciones sistemáticas entre los resultados de diferentes algoritmos para una misma instancia, potencialmente aumentando la probabilidad de error tipo I en las comparaciones.
- **Variabilidad de hardware:** Las mediciones de tiempo podrían verse afectadas por variaciones en la

carga del sistema durante las ejecuciones. A pesar de nuestros esfuerzos por minimizar procesos en segundo plano durante los experimentos, fluctuaciones en el rendimiento del sistema podrían haber afectado los tiempos medidos, especialmente para algoritmos con ejecuciones muy rápidas donde incluso pequeñas variaciones representan un porcentaje significativo del tiempo total.

- **Elección de pruebas estadísticas:** La selección del test de Friedman alineado, aunque justificada por su mayor potencia estadística en comparación con el test de Friedman clásico, podría resultar en conclusiones diferentes a las que se obtendrían con otras pruebas no paramétricas como el test de Quade o ANOVA de Friedman. Estudios recientes sugieren que diferentes pruebas pueden ser más apropiadas dependiendo de las características específicas de los datos experimentales.
- **Tamaño del efecto:** A pesar de reportar el estadístico A12 de Vargha-Delaney, existe debate en la comunidad científica sobre los umbrales apropiados para interpretar la magnitud práctica de las diferencias. Los umbrales utilizados (pequeño >0.56, mediano >0.64, grande >0.71) podrían no ser universalmente aplicables a todos los dominios de problemas algorítmicos.
- **Representación gráfica:** Los diagramas de diferencia crítica (CD), si bien son informativos, pueden simplificar excesivamente las relaciones entre algoritmos al agruparlos basándose únicamente en un umbral de significancia estadística, sin considerar la magnitud de las diferencias en rendimiento.
- **Corrección por comparaciones múltiples:** Aunque la prueba post-hoc de Nemenyi incluye correcciones para comparaciones múltiples, estas correcciones podrían ser demasiado conservadoras en escenarios con numerosos algoritmos, potencialmente ocultando diferencias reales (error tipo II).

Para mitigar estas limitaciones, recomendamos que trabajos futuros consideren un enfoque multimetodológico, incorporando diversos tests estadísticos y empleando *bootstrapping* para evaluar la robustez de los resultados frente a diferentes metodologías de análisis.

6. Conclusiones y Trabajo Futuro

Este estudio presentó una evaluación comparativa rigurosa de dieciséis algoritmos metaheurísticos bioinspirados aplicados al problema VRP. Las principales conclusiones son:

1. El análisis estadístico avanzado establece cuatro grupos de rendimiento estadísticamente diferenciados, con WOA, FSA, MRFO y SMA formando el grupo de élite sin diferencias significativas entre ellos.

2. SMA ofrece el mejor equilibrio calidad/coste, requiriendo aproximadamente la mitad del tiempo computacional que WOA con calidad de solución equivalente.
3. Los algoritmos mostraron comportamiento diferenciado según el tipo de instancia, sugiriendo potencial para estrategias de selección adaptativa.
4. El análisis de tamaños de efecto A12 complementa la significancia estadística, cuantificando la magnitud práctica de las diferencias entre algoritmos.

Como trabajo futuro, proponemos:

1. Evaluar el rendimiento en instancias de mayor tamaño (Homberger, 200–400 clientes) para analizar la escalabilidad de los algoritmos.
2. Implementar un análisis de sensibilidad para examinar el impacto de parámetros críticos (población, iteraciones) en la calidad de solución y tiempo de ejecución.
3. Desarrollar algoritmos híbridos que combinen las estrategias más efectivas identificadas en este estudio.
4. Extender el análisis a otros problemas de optimización combinatoria para evaluar la generalidad de nuestros hallazgos.

Una línea de investigación inmediata consiste en extender la evaluación a instancias de mayor tamaño, particularmente las de Homberger con 200 y 400 clientes, que presentan distribuciones espaciales y restricciones horarias más exigentes. Esperamos que el análisis estadístico en estas instancias confirme—o matice—las conclusiones obtenidas para las series Solomon, revelando posibles problemas de escalabilidad en ciertos algoritmos. Además, planeamos investigar variantes dinámicas del VRP que incorporen pedidos en línea y ventanas temporales estocásticas, donde la rapidez de reacción es tan importante como la calidad de la solución. Finalmente, consideraremos la hibridación del operador de exploración global de OPA-D con los mecanismos adaptativos de peso de SMA, buscando un balance todavía más favorable entre coste computacional y calidad. Estos experimentos, junto con un contenedor Docker para facilitar la replicación, formarán parte de una versión extendida que pretendemos enviar a una revista Q1 de ciencias de la computación.

Agradecimientos

Agradezco profundamente a mi profesor guía, Rodrigo Olivares, por su invaluable apoyo y orientación durante el desarrollo de esta investigación. Asimismo, agradezco al Programa de Magíster en Informática de la Universidad de Valparaíso por brindarme las herramientas y el entorno necesarios para llevar a cabo este trabajo. Finalmente, extendiendo mi agradecimiento a la Universidad de Valparaíso por su apoyo institucional.

A. Apéndice de Reproducibilidad

Para garantizar la reproducibilidad completa de este estudio, ponemos a disposición de la comunidad científica los siguientes recursos y procedimientos detallados. El principio fundamental de nuestro enfoque ha sido garantizar la transparencia y reproducibilidad en cada etapa del proceso experimental.

A.1. Recursos disponibles

- **Código fuente completo:** Disponible con control de versiones en <https://github.com/kaosb/BioAlgoCompare/releases/tag/v1.0.0>, incluyendo la implementación detallada de todos los algoritmos y componentes experimentales.
- **Datos de benchmarking:** Resultados completos en formato CSV: `results/bio16_solomon/summary.csv`
- **Parámetros de configuración:** Archivos de configuración específicos para cada algoritmo en formato JSON.
- **Instancias de prueba:** Todas las instancias Solomon utilizadas en formato estándar en el directorio `data/vrp/Solomon/`.
- **Scripts de análisis:** Código para reproducir todas las figuras y análisis estadísticos en `scripts/analyze.py`.
- **Resultados intermedios:** *Checkpoints* de las ejecuciones para facilitar verificaciones y análisis adicionales.

A.2. Entorno de ejecución

El proyecto incluye un archivo `requirements.txt` con todas las dependencias necesarias, especificando versiones exactas para evitar problemas de compatibilidad:

```
1 numpy==1.23.5
2 pandas==1.5.3
3 matplotlib==3.7.1
4 scipy==1.10.1
5 scikit-posthocs==0.7.0
6 networkx==3.1
7 seaborn==0.12.2
8 tabulate==0.9.0
9 tqdm==4.65.0
10 click==8.1.3
11 joblib==1.2.0
12 PyYAML==6.0
13 scikit-learn==1.2.2
14 psutil==5.9.0
```

Para facilitar el uso en entornos diversos, también proporcionamos un `Dockerfile` que permite ejecutar todos los experimentos en un entorno completamente aislado y reproducible:

```
1 FROM python:3.10-slim
2
3 WORKDIR /app
```

```

4
5 COPY requirements.txt .
6 RUN pip install --no-cache-dir -r
  requirements.txt
7
8 COPY . .
9
10 # Comando para ejecutar benchmarks
11 ENTRYPOINT ["python", "scripts/run_massive.
  py"]

```

A.3. Instrucciones detalladas de reproducción

Los comandos para reproducir el análisis completo son:

```

1 # Clonar repositorio
2 git clone https://github.com/kaosb/
  BioAlgoCompare.git
3 cd BioAlgoCompare
4
5 # Crear entorno virtual
6 python -m venv venv
7 source venv/bin/activate # En Linux/Mac
8 # o
9 venv\Scripts\activate # En Windows
10
11 # Instalar dependencias
12 pip install -r requirements.txt
13
14 # Ejecutar benchmarks masivos (advertencia:
  proceso de larga duracion)
15 python scripts/run_massive.py \
16 --instances "C101,R101,RC101,C201,R201,
  RC201" \
17 --algorithms "egto,foa,woa,hho,mrfo,sma
  ,aha,apo,ewa,gto,gvoa,opa,rro,sho,

```

```

18 smo" \
19 --runs 1000 --iterations 100 --
  population 40 \
20 --parallel --checkpoint-dir ./
  checkpoints \
21 --output-dir ./results/
  bio16_solomon_timed
22
23 # Generar analisis estadistico completo
24 python scripts/analyze.py stats \
25 --csv results/bio16_solomon_timed/
  massive_benchmark_summary.csv \
26 --out benchmark_comparisons/
  solomon_final \
27 --generate-tables --generate-figures \
28 --cd-diagram --stat-report
29
30 # Generar figuras adicionales
31 python scripts/analyze.py visualize \
32 --csv results/bio16_solomon_timed/
  massive_benchmark_summary.csv \
33 --out figures \
  --convergence --boxplots --scatter

```

A.4. Verificación de resultados

Los comandos para verificar la correcta reproducción se centran en comparar los valores de *fitness* obtenidos con los reportados en la Tabla 3 y comprobar que las diferencias no excedan el 1 % para ningún algoritmo. Adicionalmente, el diagrama CD de la Fig. 3 debe mostrar agrupaciones consistentes con las reportadas en este artículo, aunque pequeñas variaciones en los *rankings* exactos son esperables debido a la naturaleza estocástica de los algoritmos.

Referencias

- [1] S. Mirjalili and A. Lewis, “The whale optimization algorithm,” *Advances in Engineering Software*, vol. 95, pp. 51–67, 2016.
- [2] X. Li et al., “Slime mould algorithm: A new method for stochastic optimization,” *Future Generation Computer Systems*, vol. 111, pp. 300–323, 2020.
- [3] G. Contreras-Saavedra et al., “Critical difference diagrams for multiple comparison tests in metaheuristics research,” *Applied Soft Computing*, vol. 133, 2024, Art. no. 110016.
- [4] J. P. Silva et al., “A comprehensive comparative study of bio-inspired algorithms for the VRP,” *IEEE Access*, vol. 11, pp. 14532–14547, 2023.
- [5] S. Mirjalili et al., “Harris hawks optimization: Algorithm and applications,” *Future Generation Computer Systems*, vol. 97, pp. 849–872, 2019.
- [6] N. Hamadneh et al., “FOA: A novel fossa optimization algorithm for global optimization and feature selection,” *Expert Systems with Applications*, vol. 233, 2024, Art. no. 120759.
- [7] B. Abdollahzadeh et al., “GTO: Gorilla troops optimizer,” *Neural Computing and Applications*, vol. 33, pp. 2309–2345, 2021.
- [8] M. M. Hassan et al., “Enhanced gorilla troops optimizer for global optimization tasks,” *Swarm and Evolutionary Computation*, vol. 80, 2024, Art. no. 101270.
- [9] A. A. Heidari et al., “Harris hawks optimization: Algorithm and applications,” *Future Generation Computer Systems*, vol. 97, pp. 849–872, 2019.
- [10] Y. Wang et al., “Flamingo search algorithm: A novel nature-inspired metaheuristic for global optimization,” *Knowledge-Based Systems*, vol. 216, 2021, Art. no. 106510.
- [11] R. Zamani et al., “Starling murmuration optimizer: A novel algorithm for global optimization,” *Expert Systems with Applications*, vol. 199, 2022, Art. no. 116924.
- [12] W. Zhao et al., “Manta ray foraging optimization: An effective bio-inspired optimizer for engineering applications,” *Engineering Applications of Artificial Intelligence*, vol. 87, 2020, Art. no. 103300.
- [13] M. Elsisí et al., “Integración de redes neuronales profundas en SMA para CVRP,” *Procedia Computer Science*, vol. 207, pp. 3058–3067, 2023.
- [14] Q. Wang et al., “Artificial protozoa optimizer: A new metaheuristic for global optimization,” *Soft Computing*, 2024 (en prensa).
- [15] W. Zhao et al., “Artificial hummingbird algorithm: A new bio-inspired optimizer,” *Computers & Industrial Engineering*, vol. 168, 2022, Art. no. 108119.
- [16] G. Wang et al., “Earthworm optimization algorithm: A bio-inspired metaheuristic for global optimization problems,” *Journal of Intelligent Manufacturing*, vol. 29, pp. 1063–1077, 2018.
- [17] A. Brabazon et al., “Raven roosting optimization: A new metaheuristic for solving problems,” *Natural Computing*, vol. 15, pp. 345–364, 2016.
- [18] M. A. Hasan et al., “Griffon vultures optimization algorithm for global optimization tasks,” *Mathematics and Computers in Simulation*, vol. 200, pp. 131–154, 2025.
- [19] B. Liang et al., “A hybrid harmony-mayfly algorithm for the CVRPTW,” *Transportation Research Part E*, vol. 174, 2023, Art. no. 103127.
- [20] J. F. Rodríguez-Álvarez et al., “Complementary skewed VNS for robust VRP under uncertainty,” *European Journal of Operational Research*, vol. 302, pp. 122–138, 2024.
- [21] A. Vargha and H. D. Delaney, “A critique and improvement of the CL common language effect size statistics of McGraw and Wong,” *Journal of Educational and Behavioral Statistics*, vol. 25, no. 2, pp. 101–132, 2000.